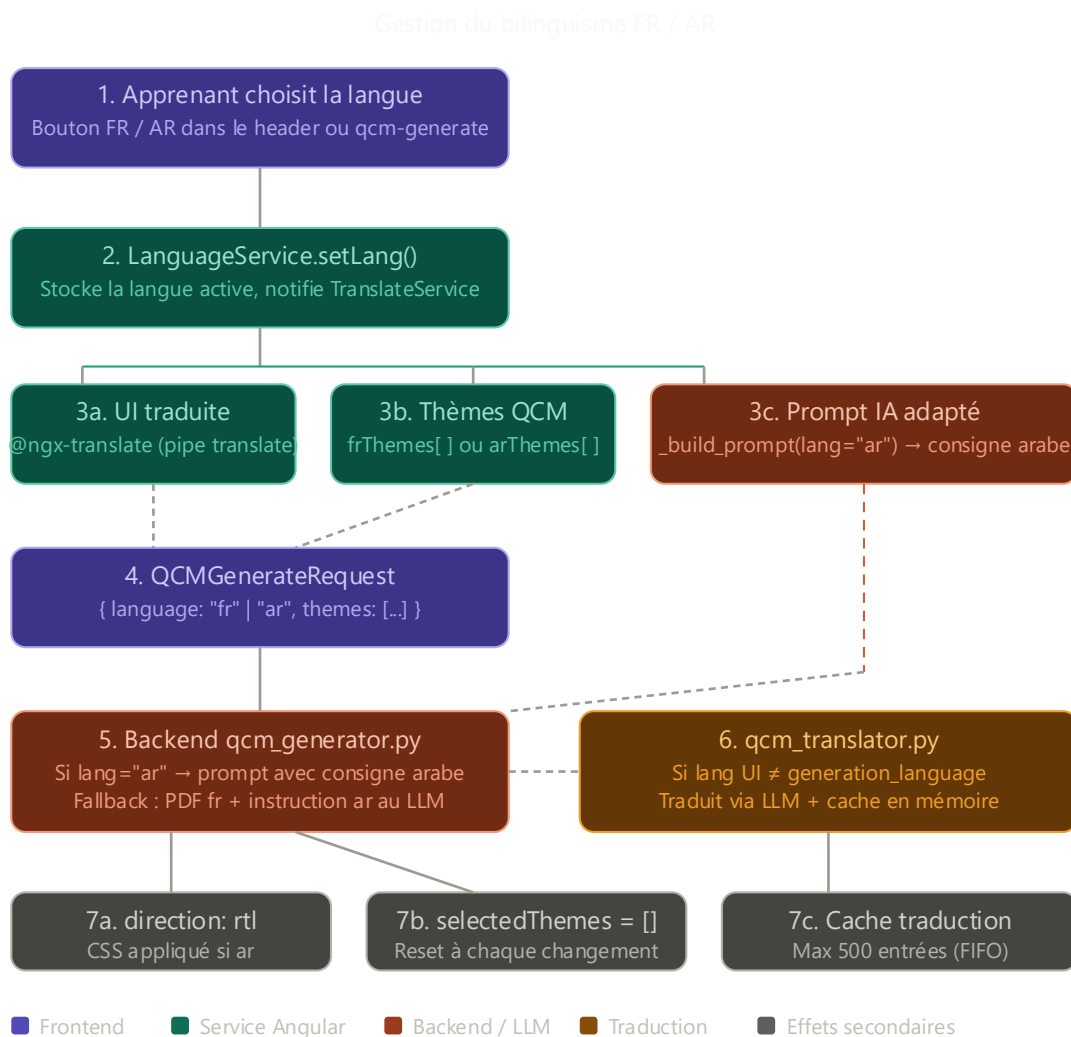


Partie 1 — Le bilinguisme (FR/AR)




Comment fonctionne le bilinguisme concrètement :

Le bilinguisme opère sur **trois niveaux distincts et indépendants**.

Niveau 1 — L'interface utilisateur : TranslateService de @ngx-translate traduit tous les labels, boutons et messages de l'UI via le pipe | translate dans les templates HTML. Les fichiers de traduction XLIFF contiennent les équivalents FR/AR de chaque clé. Quand l'apprenant change de langue, onLangChange se déclenche et tous les textes se mettent à jour instantanément sans rechargement de page.

Niveau 2 — Les thèmes du formulaire : qcm-generate.ts maintient **deux tableaux séparés** (frThemes et arThemes) de 11 thèmes chacun. La propriété calculée availableThemes retourne l'un ou l'autre selon this.language. Si l'apprenant change de langue, selectedThemes est réinitialisé à [] pour éviter d'envoyer des thèmes en français quand la langue choisie est l'arabe.

Niveau 3 — La génération et la traduction : Le paramètre language est inclus dans le QCMGenerateRequest envoyé au backend. qcm_generator.py construit alors un prompt différent selon la langue. Pour l'arabe, une consigne explicite en arabe est insérée dans le prompt pour forcer le LLM à répondre exclusivement en arabe, même si le PDF de contexte est en français. Enfin, si l'apprenant recharge un QCM déjà généré dans une autre langue via qcm_translator.py, une traduction à la volée est effectuée avec un cache en mémoire de 500 entrées (FIFO) pour éviter de rappeler le LLM pour le même contenu.



Comment fonctionne la génération automatique concrètement :

① ② **Configuration et validation** : L'apprenant remplit le formulaire (qcm-generate.ts) et le frontend envoie un POST /api/qcm/generate avec { mode, language, difficulty, question_count, themes }. Le backend vérifie immédiatement le token JWT, que question_count vaut 5 ou 10, et qu'un thème est fourni si le mode est "spécifique".

③ ④ **Contexte et prompt** : qcm_generator.py charge le PDF de cours (limité à 5 000 caractères) et construit un prompt précis pour le LLM. Ce prompt contient la langue, la difficulté, le thème, le contexte documentaire, et une banque de 22 mots-clés d'images de panneaux routiers que l'IA peut utiliser pour illustrer ses questions.

⑤ **Appels LLM par lots** : Le LLM Groq (LLaMA) est appelé en **lots de 4 questions** avec un délai de 5 secondes entre chaque lot pour respecter la limite gratuite de 6 000 tokens/minute. Si l'API répond "trop de requêtes", un mécanisme de retry attend automatiquement le délai suggéré par Groq, avec un maximum de 4 tentatives.

⑥ ⑦ **Nettoyage et images** : Le JSON retourné par le LLM est souvent imparfait (guillemets typographiques, virgules incorrectes, accolades non fermées). Une série de corrections automatiques le rend exploitable. Ensuite, chaque image_keyword proposé par l'IA (ex : panneau_stop) est remplacé par l'URL Wikimedia réelle correspondante.

⑧ **Filtrage des doublons** : Les nouvelles questions sont comparées aux 500 dernières questions déjà générées via deux algorithmes : Jaccard (75% de mots en commun = doublon) et SequenceMatcher (90% de similarité de caractères = doublon). Les doublons détectés sont éliminés.

⑨ **Sauvegarde** : Les entités QCM, Question et Answer sont persistées en base avec le flag is_generated=True et created_by lié à l'utilisateur. Le backend retourne le qcm_id au frontend.

⑩ ⑪ ⑫ **Session** : Le frontend navigue vers /qcm-session/:id?generated=1. Ce paramètre force l'utilisation de la route GET /api/qcm/generated/:id (qui vérifie que le QCM appartient bien à l'utilisateur). Les questions s'affichent une par une avec timer, sans feedback visuel immédiat (les corrections ne sont pas montrées entre chaque question, contrairement aux QCM statiques).

⑬ ⑭ **Résultats** : Toutes les réponses sont soumises en une requête POST /api/qcm/generated/:id/submit. Le backend calcule le score, enregistre un UserQCMResult, et retourne le détail complet. La page résultat (qcm-resultat) affiche le score, chaque question avec la bonne réponse et l'explication fournie par l'IA.